

基于异构企业历史数据的 Vector-RAG 与 GraphRAG 性能对比研究

蔡昌言、李开宇、李一杰、刁亚冲、刘炳泽

2026 年 6 月 9 日

摘要

随着大语言模型 (LLM) 在企业级知识管理中的广泛应用, 图检索增强生成 (GraphRAG) 因其在处理跨文档、全局宏观问题上的理论优势, 逐渐成为业界焦点。然而, GraphRAG 在真实且充满噪声的企业异构数据上的实际表现是否如预期般卓越? 本文聚焦于某公司 10 年发展历程的异构数据集 (涵盖财报、邮件、新闻等共 109 篇, 约 14 万 Tokens), 系统性构建并对比了基于多层级切分与重排优化的 Vector-RAG, 以及基于大模型实体抽取的 GraphRAG。

依托 Ragas 评测框架在单文档、跨文档及全局三类测试集上的量化评估, 本研究得出了具有启发性的实证结果: 在当前的实验规模与约束下, 深度优化的 Vector-RAG 在五大核心评测指标上均实现了对 GraphRAG 的超越, 且其推理延迟仅为后者的极小部分 (约 10 秒 vs 最高 229 秒)。针对这一反直觉现象, 本文深入探讨了基座模型参数规模、图谱数据量级以及异构数值转化对 GraphRAG 性能的潜在制约, 为企业级 RAG 系统的架构选型与能力边界探索提供了客观、严谨的工程指导与未来展望。

关键词: 检索增强生成; Vector-RAG; GraphRAG; 知识图谱; 能力边界; 实证评估

1 引言

1.1 研究背景与动机

在企业数字化转型与知识管理的演进进程中, 组织内部积累了跨越长周期的海量异构非结构化数据。检索增强生成 (Retrieval-Augmented Generation, RAG) [1] 作为一种将外部知识库与大模型解耦融合的范式, 已成为解决垂直领域“知识幻觉” (Hallucination) [2] 与上下文窗口限制的主流架构。

1.2 理论困境与 GraphRAG 的兴起

现有的经典 RAG 范式 (Vector-RAG) 高度依赖于文本块切分与连续稠密向量空间的相似度匹配。理论上, 该策略在面临结构错综复杂的企业级长文本时, 容易陷入“上下文语义割裂”与“宏观推理匮乏”的局限, 尤其是在回答需要跨越 10 年发展脉络的全局性问题 (Global Queries) 时。

为突破上述理论瓶颈，图检索增强生成（GraphRAG）[3] 应运而生。它试图通过知识图谱（KG）抽取与层次化的社区发现算法，在全球搜索机制下实现高阶的信息同构与全景洞察。近年来，业界普遍假设 GraphRAG 将在复杂推理和全局总结任务上彻底颠覆传统 Vector-RAG。

1.3 研究目标：一次批判性的实证检验

尽管 GraphRAG 概念火热，但一个核心的科学疑问亟待解答：**在面对真实业务中长短程语义交织、包含高密度财务数字与口语化邮件的异构数据集时，GraphRAG 的实际表现真的优于经过深度工程优化的 Vector-RAG 吗？**

为回答这一问题，本文开展了严密的控制实验。本研究的核心贡献如下：

- **构建异构评测基准：**清洗并整合了企业 10 年间 109 篇异构语料，为长文本 RAG 研究提供了真实的测试床。
- **提出深度调优的双线架构：**实现了一套以“三级树状切分 + 多路重排”为核心的极优 Vector-RAG 管道，以及一套标准的多层级 GraphRAG 管道。
- **多维度实证祛魅：**借助 Ragas 框架 [4]，从准确率、相关性到推理耗时进行了全方位对比，以详实的数据揭示了当前 GraphRAG 范式的潜在工程陷阱。




图 1: Vector-RAG 与 GraphRAG 系统架构及检索生成流程对比图

2 实验方案与技术实现

2.1 数据源构建与零样本预处理特征

本研究构建的数据集涵盖了某组织连续 10 年的核心文本, 总量计 109 篇, 共 140,765 Tokens, 单篇平均 1,291 Tokens。为了评估系统应对噪声数据的鲁棒性, 本研究在导入阶段**未施加任何启发式的人工清洗**。数据源量化分布如表 1 所示。

表 1: 10 年期企业异构数据集量化统计与特征描述

数据类型 (Data Type)	篇数	总 Tokens	篇均 Tokens	核心语义特征
财务报告 (Financial Reports)	11	36,468	3,315	结构高度模块化, 高密度的数字收支与宏观趋势指标
往来邮件 (Corporate Emails)	44	35,362	803	口语化严重, 具备强烈的事件驱动与时序演进特征
会议纪要 (Meeting Minutes)	8	17,659	2,207	交互式对话, 实体关系密集, 逻辑多线并行
新闻媒体报道 (Media Reports)	20	32,607	1,630	叙事性文本, 时效性强, 含有较多外部实体引用
内部文档 (Internal Documents)	26	18,669	718	规范性文本, 概念定义严谨, 呈树状层级结构
总计 (Total)	109	140,765	1,291	横跨 10 年周期, 长程语义交织的异构实体网络

2.2 Vector-RAG 架构设计与调优

为回击传统向量检索“上下文割裂”的理论劣势, 本文在 Vector-RAG 流水线中引入了多级切分与重排机制。

2.2.1 多层次树状切分机制

本文采用了严格的三级树状节点切分策略:

- **叶子节点 (256 Tokens):** 作为稠密向量化与底层检索的最基本单元, 极大提升了对细粒度事实 (如特定财报数据) 的召回灵敏度。
- **父级中间节点 (1024 / 2048 Tokens):** 窗口重叠度精细控制为 30 Tokens。底层子块被召回后, 系统自动回溯并替换为对应的父块投喂给大模型, 完美兼顾了“高精度检索”与“大视域上下文”。

2.2.2 向量化与多路重排检索

叶子节点采用 `bge-embedding-m3` [5] 进行向量表征。召回阶段结合假设性文档 (HyDE) [6] 进行多路召回, 并在最终输入生成模型前串联 `bge-reranker` 进行全局二次重排。

2.3 GraphRAG 图谱构建与架构

作为对照组, 本文实现了一套标准的 GraphRAG 架构。

2.3.1 异构知识网络构建与可视化

文本采用 800 Tokens (Overlap=200) 窗口切分, 送入 `qwen2.5-14b-awq` [7] 提取实体与关系。如图 2 所示, 经过聚合后, 整个异构数据呈现出显著的无标度网络特性。




图 2: 基于 10 年数据生成的 GraphRAG 整体知识图谱网络拓扑

2.3.2 多层次社区划分与全局搜索

应用层次化社区发现算法（如 Leiden 算法 [8]）将图谱划分为 4 个特定网络层级（Levels 0-3），并针对各个社区预生成自然语言摘要：

- **Level 0 (顶层宏观社区 - 23 个摘要)：**涵盖长周期战略演进与宏观发展趋势。
- **Level 1 (中高层社区 - 99 个摘要)：**承接宏观概括与中观事实，负责较大范围事件归纳。
- **Level 2 (中低层社区 - 83 个摘要)：**聚焦具象业务实体网络与局部交互。
- **Level 3 (底层微观社区 - 4 个摘要)：**处于最底层，聚焦局部异常集群与细粒度事件。

问答阶段采用全局搜索（Global Search）范式，由 `qwen-2.5-7b-awq` 采用 Map-Reduce 架构进行全局语义规约。

3 实验设置与评估指标

3.1 评测数据集与评估基准

基于 109 篇历史文献反向生成了共计 30 道测试题，划分为 **Single (局部单点事实)**、**Multi (跨文档跳跃推理)** 和 **Global (全局宏观总结)** 三种粒度。引入 Ragas 框架 [4]，以 `qwen2.5-14b-awq` 作为裁判模型，重点观测 Faithfulness、Answer Relevancy、Context Recall、Context Precision 和 Answer Correctness 五大核心指标。

4 实验结果与分析

4.1 多维评测指标对比

图 3 展示了 Vector-RAG (VRAG) 与 GraphRAG 四个层级 (GRAG-0 至 GRAG-3) 在三类测试集上的雷达图表现。




图 3: Vector-RAG 与 GraphRAG (Level 0-3) 在三类测试集上的 Ragas 多维评测雷达图。深蓝色虚线代表 VRAG，在当前实验约束下构成了最大的外围面积。

实证数据呈现出了与当前业界普遍预期相左的结果：在本次企业异构数据集的测试中，Vector-RAG 在所有问题粒度和主要评测指标上，均保持了对 GraphRAG 的领先。

- **VRAG 的高精度与鲁棒性：**代表 VRAG 的深蓝色虚线在所有粒度下均构成了最大多边形。尤其是在 Context Precision 和 Answer Correctness 上，VRAG 始终逼近满分。这证明“三级树状切分 + 全局重排”机制极大弥补了传统向量检索的缺陷，能够跨越异构数据的干扰，精准锁定高价值上下文。
- **GraphRAG 的表现回落：**GRAG 的得分普遍收敛于 0.2 - 0.4 区间。即使在理论上应占优的 Global（全局总结）任务中，其 Context Recall 也未能实现反超。这表明在当前的建图策略下，异构文本中的关键数字与细微时序在转化为“关系三元组”和“宏观摘要”时发生了不可忽视的信息丢失。

4.2 推理耗时与计算成本分析

在工业落地中，推理延迟极其关键。表 2 记录了不同架构在三类测试集上的平均生成耗时（单位：秒）。

数据进一步凸显了 GraphRAG 的计算成本劣势：

1. **VRAG 的高效与稳定：**得益于向量近似最近邻搜索（ANN），VRAG 的耗时稳定在极低的 10 秒左右，展现出绝佳的工程可用性。
2. **GRAG 的耗时膨胀：**GraphRAG 的延迟受限于 Map-Reduce 的并发与规约复杂度。Level 3 虽然仅有 4 个摘要，但因为处于微观实体底层，计算极度复杂，耗时逼近 230 秒。即便是高度抽象的 Level 0，其在复杂问题上的耗时也超过 VRAG 的两倍。

表 2: Vector-RAG 与 GraphRAG (不同层级) 的平均回答生成时间对比 (秒)

检索架构	并发摘要规模	Global (全局)	Multi (跨文档)	Single (单篇)
Vector-RAG	Top-K 文本块	10.21	10.53	9.85
GraphRAG (Level 3)	4 个微观摘要	229.77	219.23	182.76
GraphRAG (Level 2)	83 个中低层摘要	224.25	213.24	111.75
GraphRAG (Level 1)	99 个中高层摘要	97.32	67.48	29.46
GraphRAG (Level 0)	23 个顶层摘要	22.35	18.14	10.00

5 讨论与未来展望

“GraphRAG 是否必然优于优化的 Vector-RAG?” 本研究基于 10 年期企业异构数据的多维评测，在当前的实验边界下给出了否定的答案。然而，本研究的目的并非全盘否定 GraphRAG 的理论价值，而是旨在探索其在真实场景中的**能力边界条件 (Boundary Conditions)**。针对 GraphRAG 在本实验中的表现不佳，我们提出以下三个维度的科学猜想与局限性分析：

5.1 性能衰减的科学猜想 (Hypotheses for Underperformance)

- 大模型参数规模的推理天花板：**本实验在建图阶段 (Indexing) 采用了 14B 参数规模的模型 (qwen2.5-14b-awq)。异构企业数据（特别是包含晦涩商业术语的内部文档与高密度财报）的实体抽取与深层逻辑推演难度极高。14B 模型的指令遵循和复杂关系表征能力可能尚未达到构建无损全局知识图谱的临界阈值，从而在源头上导致了图谱的“信息有损压缩”。
- 数据量级的非舒适区：**知识图谱的涌现能力往往依赖于海量数据。本实验的数据集总计 109 篇（约 14 万 Tokens），在此规模下，优化的 Vector-RAG 配合大窗口模型已能覆盖大部分语境。GraphRAG 的真正优势（即在数百万甚至上亿 Tokens 数据中跨越孤岛建立弱连接）在当前“中小型”数据规模下难以被充分激活，反而暴露了其沉重的计算开销。
- 异构模态与图谱结构的天然错配：**企业数据中包含大量结构化的财务数字与表格。当前的 GraphRAG 范式偏向于抽取“主谓宾”关系网络，在处理纯粹的数值比较与连续时间序列数据时缺乏原生的图结构映射方案 (Schema)，导致此类关键事实在社区归纳中被作为“噪声”清洗，进而造成 Single 任务的溃败。

5.2 结论与工程建议

实验数据表明，在处理中等规模（约 10 万 Tokens 级别）、混合模态的企业级语料时，**深度优化的 Vector-RAG（集成树状切分与多路重排）**无论在检索精度、事实忠实度，还是在计算耗时上，依然是当前兼顾效果与成本的最佳工业实践。

面向未来，随着千亿级乃至万亿级大模型的推理成本下降，以及支持多模态或数值原生的复杂图数据库架构的成熟，GraphRAG 有望在超大规模数据集上释放其真正的潜力。未来的知识问答系统不仅需要在单一范式上深耕，更应探索基于意图路由的混合增强架构 (Hybrid-RAG)。

参考文献

- [1] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., ... & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive nlp tasks. *Advances in Neural Information Processing Systems*, 33, 9459-9474.
- [2] Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., ... & Fung, P. (2023). Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12), 1-38.
- [3] Edge, D., Trinh, H., Cheng, X., Bradley, J., Chao, A., Mody, A., ... & Larson, B. (2024). From local to global: A graph rag approach to query-focused summarization. *arXiv preprint arXiv:2404.16130*.
- [4] Es, S., James, J., Espinosa-Anke, L., & Schockaert, S. (2023). Ragas: Automated evaluation of retrieval augmented generation. *arXiv preprint arXiv:2309.15217*.
- [5] Chen, J., Xiao, S., Zhang, P., Luo, K., Lian, D., & Liu, Z. (2024). BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation. *arXiv preprint arXiv:2402.03216*.
- [6] Gao, L., Ma, X., Lin, J., & Callan, J. (2022). Precise zero-shot dense retrieval without relevance labels. *arXiv preprint arXiv:2212.10496*.
- [7] Qwen Team. (2024). Qwen2 Technical Report. *arXiv preprint arXiv:2407.10671*.
- [8] Traag, V. A., Waltman, L., & van Eck, N. J. (2019). From Louvain to Leiden: guaranteeing well-connected communities. *Scientific reports*, 9(1), 5233.

A 定性生成案例对比 (Qualitative Case Studies)

为了直观展示 Vector-RAG 与 GraphRAG 在不同粒度问题上的生成差异，本附录从 Single (局部单点)、Multi (跨文档推理) 及 Global (全局宏观) 三个测试集中各抽取了一个典型案例进行无干预的原始回答对比。

(1) 全局宏观推理

Question: 纵观 AetherCore 从 2015 年上市到 2025 年站在新十年门槛的完整历程，其核心战略逻辑与业务边界经历了哪几个根本性的阶段跃迁？每个阶段转型的驱动因素是什么？

(1a) Vector-RAG

Answer: AetherCore 自 2015 年上市以来，其核心战略与业务边界经历了以下跃迁：

阶段一：2015-2021 年 (初创与商业化落地)

- **核心逻辑：** 从专注芯片研发发展为具商业竞争力的企业。2015 年营收 1.25 亿美元，但因高额研发及 IPO 支出录得净亏损。
- **驱动因素：** 市场对高性能芯片需求增加；技术突破；IPO 筹资支持。

阶段二：2021-2023 年 (应对地缘政治与市场调整)

- **核心逻辑：** 剥离中国业务，转向多元化布局；设计“合规防火墙”应对不确定性。
- **驱动因素：** 中美贸易摩擦加剧；出口管制；转向日韩欧市场以减少单一依赖。

阶段三：2023-2025 年 (战略转型与长期规划)

- **核心逻辑：** 转向多元客户基础；加大研发探索新技术，避免“中型企业陷阱”。
- **驱动因素：** 面对大型科技公司竞争；解决内部技术路线争议；向可信赖推理平台商转型。

总结： 每个阶段转型均受外部环境与技术发展驱动，旨在确保可持续发展与竞争力。

(1b) GraphRAG

Answer: AetherCore 从 2015 年至今，经历了四个根本性的阶段跃迁：

- **第一阶段：从初创研发到商业化的转型** (2015 年)。驱动因素：市场需求和技术进步促使公司转向商业化运营 [Data: Reports (0)]。
- **第二阶段：供应链多元化的推进** (2015 年后)。驱动因素：地缘政治风险和单一供应商带来的风险促使寻求多元化 [Data: Reports (2, 4)]。
- **第三阶段：技术竞争的加剧** (2015 年后)。驱动因素：竞争对手的技术进步和市场策略促使加大研发力度 [Data: Reports (7, 12)]。
- **第四阶段：地缘政治风险的应对** (2015 年后)。驱动因素：国际形势变化和出口管制政策促使采取应对措施 [Data: Reports (10, 13)]。

总结： 这些阶段的转变不仅反映了战略调整，也体现了持续创新和发展。

图 4: Global 任务下的原始回答对比

(2) 跨文档推理

Question: 2016 年 8 月的分析师报告将 Meridian Systems 的 800 万美元 EdgeNode 订单视为边缘 AI 战略的‘初步验证’，但同年 10 月 Marcus Chen 的辞职邮件却揭示了该订单与 GreenWave 诉讼之间的何种具体传导风险？这一风险又如何反证了公司当时‘合规防火墙’的真实状态？

(2a) Vector-RAG

Answer: 基于财务上下文，Meridian Systems 的 800 万美元 EdgeNode 订单与 GreenWave 诉讼之间的传导风险及合规状态分析如下：

1. 具体传导风险

- **禁令违约风险：** GreenWave 申请初步禁令阻止销售含 DVFS 模块的产品。若无替代方案，公司将无法按时交付 Meridian 订单，直接导致违约并丧失 800 万美元收入。
- **无上限赔偿条款：** Meridian 采购协议中包含无上限的 IP 侵权赔偿条款。若被判侵权或无法交货，赔偿金恐达数百万美元，甚至吞噬全年毛利。
- **大客户连锁反应：** Nimbus Cloud 框架协议含最惠 IP 担保条款。若其因该供应链风险而暂停采购，公司将失去占全年营收 58% 的基本盘。

2. 合规防火墙的真实状态

- **决策预判不足：** 2016 年 8 月 CEO Elena Voss 明确需从 Titan-1 利润中划拨 1500 万美元用于 EdgeNode 研发，表明高层对订单的潜在法律风险严重估计不足。
- **财务风控缺失：** Marcus Chen 在 10 月辞职信中拒绝在 Q3 财报中足额计提诉讼准备金，暴露出财务风险管理的迟滞。
- **系统性合规薄弱：** CFO 为规避法律风险而辞职，直接证明公司未能建立起有效的内部“合规防火墙”，风险控制体系存在明显漏洞。

总结： 该订单与诉讼间的传导风险，集中暴露了公司在顶层决策、财务风控及风险隔离体系上的严重合规缺失。

(2b) GraphRAG

Answer: 2016 年 8 月，分析师报告将 Meridian Systems 的 800 万美元 EdgeNode 订单视为边缘 AI 战略的“初步验证”。然而，同年 10 月，Marcus Chen 的辞职邮件揭示了该订单与 GreenWave 诉讼之间存在具体的传导风险，主要集中在以下两个方面：

- **违反出口管制法规的风险：** Marcus Chen 的辞职邮件揭示了该订单可能涉及违反出口管制法规的行为，不符合国际标准。这种风险不仅影响到订单本身，还可能波及整个公司的合规性问题 [Data: Reports (6, 7, 8, 9, 10, +more)]。
- **合规防火墙的有效性：** 邮件指出该订单可能因 GreenWave 诉讼而面临法律风险。这揭示了公司当时的“合规防火墙”可能并不完善，无法有效隔离不同业务板块之间的法律风险 [Data: Reports (81)]。

总结与真实状态： 尽管该订单被视为战略的重要里程碑，但 Marcus Chen 的辞职邮件进一步揭示，公司的合规防火墙并未有效隔离风险，反而加剧了法律和财务压力 [Data: Reports (27, 76)]。综上分析，订单背后的合规风险暴露了公司整体合规体系的有效性不足，表明存在未充分解决的合规隐患 [Data: Reports (1, 2, 3, 4, 5, 122, +more)]。

图 5: Multi 任务下的原始回答对比

(3) 局部单点事实推理

Question: 在 2015 年 11 月的执委会上，销售 VP Sarah Lindstrom 主张将 Q4 新增晶圆产能的多少比例定向供给 Nimbus Cloud？这一比例旨在换取什么类型的协议？

(3a) Vector-RAG

Answer: 2015 年 11 月执委会上，销售 VP Sarah Lindstrom 主张将台积电 28nm 产线 Q4 新增产能的 85% 定向供给 Nimbus Cloud。其核心主张与战略背景如下：

- **产能换协议（利益交换）：**旨在以高达 85% 的产能分配，换取该客户签署包含“最低采购承诺”的 2016 年独家框架协议。
- **大客户依赖（战略背景）：**这一激进的产能倾斜策略，直接反映了 Nimbus Cloud 绝对的战略核心地位——其预计将贡献公司 2016 全年 58% 的总营收。

(3b) GraphRAG

Answer: 2015 年 11 月执委会上，销售 VP Sarah Lindstrom 提出战略性资源倾斜方案：将 Q4 新增晶圆产能的 50% 定向供给 Nimbus Cloud，以期换取与该大客户的长期合作协议。该结论的具体推演逻辑如下：

- **产能分配比例辨析：**尽管少部分低权重报告提及 20%，但系统综合多份高权重信源，最终确认定向供给的核心比例为 50% [Data: Reports (27, 44-48, 53, 54, 85, 88)]。
- **合作意图定性：**相较于单纯的“独家供应”或“长期供货”，核心证据明确指出其根本目标并非短期交易，而是旨在建立稳定、持久的“长期合作协议” [Data: Reports (67, 136, 157)]。

图 6: Single 任务下的原始回答对比